Homework 2

- 1. (练习 dataframe 的添加,删除,修改,查询操作)案例小组有 4 名成员,名字分别是: zhangsan, lisi, wangwu, xiaoming, 身高分别是 175, 170, 180, 168, 性别分别是: F, M, F, M(F表示女, M代表男)。(5 分)
 - a. 请构造数据框,包含 4 位同学的信息,三列的名称分别为, name, height, gender。
 - b. 现在该小组又增加了一名女生,名字叫 xiaohong,身高 165,请将该学生加入到数据框中(提示:用 rbind 函数)
 - c. 经过考试,上次小组中 5 位同学的成绩分别是 60,40,55,55,40,将成绩加入到数据框中,列名是 score(提示:用 cbind 函数)
 - d. 请查找身高超过 170 的同学信息,保存到数据框变量 data170 中
 - e. 请查找考试分数超过 50 分的女生的信息,保存到数据框变量 femaledata50中
- 2. 请下载第三次课大家的考试成绩,由于大家系统不一样,数据有多种格式供大家使用。(10分)

CSV: score data = read.csv(file = "Exam1-score.csv");

Txt: score_data = read. table(file = "Exam1-score.txt", sep = ",", header =
TRUE);

- a. 请将数据读入 R 软件中进行分析,通过浏览整个数据看看数据中每一列的特点,第一列表示提交的顺序 ID,第二列是提交时间,第三列是考试用时,第四列表示成绩,第五列姓名,第六列是专业
- b. 结合第二次课中大家交作业的例子,找出是否同学重复提交考试(可能没有),如果有的话请删除最后一次作答成绩。
- c. 使用 plot 和 hist 函数观察各位同学的考试成绩,对大家的考试成绩特点进行 简要的分析
- d. 考试过程中有一些同学意外关闭考试网页,然后又重新进行了作答,请仔细观察数据,提供一些思路能够找出这些意外关闭考试的同学。
- e. 编写自己的函数,get_score_description,该函数的输入是 scores,返回的结果是成绩的最小值,最大值,中位数和均值,保存到向量中返回。函数定义如下:

get_score_description = function(scores)

}

f. 现在想得到每个专业的考试情况,请利用上面的函数对每个专业同学的考试成绩进行统计,保存到大数据框变量 major_score_description(提示:先按照专业的名称将数据保存到临时的数据框变量中,然后和上一步 d 中方法一样,将该专业的成绩作为参数传入函数 get_score_description 中得到统计结果,接着将专业名称和返回的结果构成一行加入到数据框变量 major_score_description中。)

- 3. 上课我们介绍了 dailyshow 的数据,请完成下面工作:
 - a. 首先用 summary 来查看数据的总体情况,回答你观察到的数据存在哪些问题
 - b. 数据清理, 提取含有 NA 的数据, 回答 NA 数据的特点
 - c. 观察 Occupation 和 Group 的数据,将由于大小写原因造成的不一致修正
 - d. 编写函数 get_top5 将 Occupation, Group, 频次最高的前 5 位的名字返回(提示,首先用函数 table 得到频次,然后 sort 之后得到大小顺序,如果要从高到低排序,请查看 sort 的帮助文档,将参数 decreasing 设置为TRUE。但是这里的数据是频次,所以要得到名字,需要用函数names()从刚才 sort 得到的结果中得到从高到低排序的名字,返回前五个即可)。(10 分)

作业要求:

- 写清楚题号和需要回答的内容
- 保证作业具有很高的可读性
- 报告和程序需要进行必要的说明,能够让没有背景知识的同学也能看懂
- 提交作业的时间是 2016 年 5 月 20 日星期五晚上 12 点,过时将认为是缺作业。
- 如果对作业题目有疑问的地方请在群里问,不要私信及问如果解答题目的细节问题,希望大家能够锻炼自己解决问题的能力!
- 所有作业用 word 完成后另存为 pdf 格式(如果不会请百度如何将 word 另存为 pdf),邮件主题和作业名字一样,格式为: DSJJYB_姓名_专业 HW2,所有作业提交至邮箱 jasonyaopku@gmail.com